

因果推断在政策评估的应用

纪传宇

2023 年 7 月 14 日

- 1 动机
- 2 衡量政策效果
- 3 检测有无遗漏变量
- 4 通过策略学习来实现更优分配
- 5 考虑公平性的有效策略选择
- 6 预期结果

政策评估作为社会科学研究领域的重要分支，致力于评估公共政策的效果和影响，一直是学者们的研究热点。在政策评估领域，研究人员使用多种方法来了解政策的实际效果。常用的方法包括匹配法、双重差分法、合成控制法、工具变量法和断点回归法等。这些方法在中国的研究中，经常应用于教育政策、环保政策、医疗补助和政府补贴等领域，为政策制定者提供科学依据和决策支持。

然而，虽然政策评估方法在揭示政策效果方面具有重要价值，但如何优化政策却鲜有研究。优化政策需要在评估政策的基础上，进一步考虑政策目标、影响因素和相关利益方的需求。

在研发补贴和科创背景下，希望通过系统梳理如何运用政策学习方法来优化政策。

近年来，政策学习在计量经济学、统计学和机器学习等领域中被广泛研究，旨在寻求最优的政策分配方案。这些研究的核心驱动主题有两个：一是开发高性能算法，以解决作为政策学习基础的经验最大化问题及其相关的放松假设；二是利用双重稳健目标来提高实际性能。

在解决经验最大化问题方面，研究人员致力于开发高效算法，以优化政策学习过程。这些算法基于统计学、优化理论和机器学习等方法，通过对大规模数据集的分析和建模，寻求最佳的政策分配方案。通过引入新的数学技术和优化方法，研究人员能够更准确地估计政策效果和优化政策决策。

与此同时，双重稳健目标的使用对于提高实际性能至关重要。双重稳健方法考虑了模型中存在的不确定性和潜在的偏差来源，以确保政策学习结果的鲁棒性和可靠性。通过将多个稳健性目标结合起来，例如平衡效应、处理潜在的内生性问题和处理非随机选择等，研究人员能够得到更加全面、可靠的政策效果估计和决策建议。

我希望通过多种因果推断方法构建出一个能评判政策分配合理度，并且通过量化指标对科创政策进行优化的一套方法。

- 衡量政策效果
- 进行有无遗漏变量的检验
- 通过策略学习来实现更优分配
- 考虑公平性的有效策略选择

双重差分 (double difference) 方法

双重差分 (Double Difference, DD) 或差异中差异 (Difference-in-Differences, DID) 方法是一种常用的计量经济学方法, 用于估计政策或干预的因果效应。它通过对处理组和对照组在时间和处理状态上的差异进行比较, 以消除时间和个体固定效应, 并减轻潜在的内生性问题。

双重差分 (Double Difference, DD) 方法的公式可以表示为:

$$\Delta Y_{it} = (\tau + \gamma_i + \lambda_t + \epsilon_{it}) - (\gamma_i + \lambda_t + \epsilon_{it})$$

其中, ΔY_{it} 是处理组 (Treatment group) 和对照组 (Control group) 在时间 t 上因变量 (Dependent variable) 的差异, τ 是我们要估计的处理效应 (Treatment effect), γ_i 是个体固定效应 (Individual fixed effect), λ_t 是时间固定效应 (Time fixed effect), ϵ_{it} 是误差项 (Error term)。

通过双重差分方法, 我们可以消除个体固定效应和时间固定效应, 从而关注于处理组和对照组之间的差异, 从中估计处理效应 (τ)。这种方法的关键在于对时间和个体的差异进行比较, 以获得因果效应的估计, 而不受个体固定效应和时间固定效应的干扰。

然而, 这种方法对数据隐含了额外的限制条件:

- 不考虑治疗效果的内生性
- $E[Y_1(1) - Y_1(0) | X, D = 1]$ 在个体特征 X 上对治疗的同质性要求。
- 对 $d = 0, 1$ $E[Y_1 - Y_0 | X, D = d] = E[Y_1 - Y_0 | D = d]$ 即在治疗组和对照组中, 排除了 X 上的不同趋势。

当这三额外的限制条件不满足时, 得到的估计值 β 不代表平均处理效应 (average treatment effect) 适用于受治疗群体 (treated group)。

处理处理效应的内生性问题:

Sant'Anna (2020) 提出的 DRDID 方法解决了内生性问题。DRDID 通过逆概率加权 (IPW) 和再次利用结果回归 (OR) 来解决选择偏差 (内生性) 的问题, 适用于高维变量和非二元处理变量的情况。这两种方法的表达式如下:

$$\hat{\tau}^{reg} = \bar{Y}_{1,1} - \left[\bar{Y}_{1,0} - \frac{1}{n_{\text{treat}}} \sum_{i|D_i=1} (\hat{m}_{0,1}(X_i) - \hat{m}_{0,0}(X_i)) \right]$$

$$\hat{\tau}^{ipw,p} = \frac{1}{E_n[W]} E_n \left[\frac{W - \hat{\pi}(X)}{1 - \hat{\pi}(X)} (Y_1 - Y_0) \right]$$

其中, $\hat{\tau}^{reg}$ 是使用结果回归方法估计的处理效应, $\hat{\tau}^{ipw,p}$ 是使用逆概率加权 (IPW) 方法估计的处理效应。

为了提高估计方法的准确性, Sant 和 Zhao (2020 年, JOE) 构建了一个双重稳健 (doubly robust)

$$\tau^{dr,p} = \mathbb{E} \left[\left(w_1^p(D) - w_0^p(D, X; \pi) \right) \left(\Delta Y - \mu_{0,\Delta}^p(X) \right) \right],$$

where, for a generic g ,

$$w_1^p(D) = \frac{D}{\mathbb{E}[D]}, \quad \text{and} \quad w_0^p(D, X; g) = \frac{g(X)(1-D)}{1-g(X)} / \mathbb{E} \left[\frac{g(X)(1-D)}{1-g(X)} \right].$$

只要 OR 或者 IPW 其中一个前提条件得到满足, 估计结果就是一致的。只要其中一个估计是正确的, 就是 $\tau^{dr,p}$ 准确的。

DRDID 方法缓解了 TWFE 方法的偏差问题, 但它有两个缺点: 首先, 它仅适用于两个时期的情况, 不能直接推广到多时期的情况, 而许多政策的实施不是在短时间就完成分配的, 而是在不同时间进行一个多期的分配与实施; 其次, 它要求面板数据要强制平衡, 不能有缺失值。在实际应用到科创政策中时, 这两个条件通常很难满足。

为此, 可以利用 Callaway 和 Sant (JoE2021) 提供了其多时期版本: CSDID。与其他修正的多时期 DID 估计方法类似, CSDID 将样本分成不同的子组, 分别估计每个组的 $ATT(g)$, 然后通过不同的策略对每个组的 ATT 进行求和, 从而得到特定时期的 ATT 。求和策略还降低了那些“潜在有偏差的组”的 ATT 的权重。

Assumptions.

- Treatment is irreversible, i.e. stag DiD. This is in line with our context: treated individuals in the Project will not drop out of the list
- Random sampling. Samples are independent of each other
- Limited treatment expectations. There is a known δ such that individuals have no expectation of being treated until the δ at which they are treated.
- Conditional parallel trend assumptions for the "never-treated group" and the "not-yet-treated group"

CSDID 方法根据正在处理的时期 g 对数据进行分组, 并分别为不同时期的每个组估计 $ATT(g, t)$ 的效应。例如, 以“从未接受治疗”作为对照组:

$$ATT_{dr}^{nev}(g, t; \delta) = E \left[\left(\frac{G_g}{E[G_g]} - \frac{\frac{p_g(X)C}{1-p_g(X)}}{E\left[\frac{p_g(X)C}{1-p_g(X)}\right]} \right) \left(Y_t - Y_{g-\bar{o}-1} - m_{g,t,\bar{\delta}}^{nev}(X) \right) \right]$$

此外, CSDID 方法提供了多种聚合所有子组的 ATT 的方式, 以满足不同的研究目的。例如, 可以进行事件研究, 研究治疗效果在子组间的一致性以及治疗效果在不同年份间的异质性等:

$$\theta = \sum_{g \in \mathcal{G}} \sum_{t=2}^{\mathcal{T}} w(g, t) \cdot ATT(g, t)$$

于是在政策评估中我们可以利用 CSDID 结合多个时期政策分配的影响来估计该政策的影响

在利用因果推断进行政策评估时，要判断所给出的解释变量是否已经能够较好的解释政策的分配机制，所以我们要进行有无遗漏变量的检验，我们使用 David Blei (2022) 提出的敏感性分析方法来进行说明。该方法的核心是倾向性评分估计的准确性。

边际敏感性模型 (MSM) 是一种治疗分配和潜在结果的模型, 其中包含了未测量混杂强度的真实值, 假设选择得分 (选择得分

$s_t(x, y) = p(T = 1 \mid X = x, Y(t) = y)$ 和倾向性评分 (倾向性评分, $e(x) = p(T = 1 \mid X = x)$) 对于在 Γ 限定的比值范围内的估计值:

$$\mathbf{B}(\Gamma) = \left\{ s(x, y) : \mathcal{X} \times \mathcal{Y} \mapsto [0, 1], \frac{1}{\Gamma} \leq \text{OR}(s(x, y), e(x)) \leq \Gamma, \text{ for all } x \in \mathcal{X} \right\}$$

Γ 的取值通过专业知识或参考观察结果来确定, 通过考虑和不考虑混杂效应之间的差异来获得。

由于我们的主要目标是学习一个优化的处理分配策略, 当这个策略已经被证明是有效后, 可以通过策略学习来实现分配。Athey 和 Wager (2021) 提出了使用观测数据进行策略学习, 以在特定问题约束条件下学习最优的治疗分配策略。该算法可以自动学习随机临床试验和观测设置下的最佳治疗分配方式。

其中比较关键的步骤是一致地估计了 Robins (1994) 提出的增广倾向性倒数权重 (AIPW) 得分: Γ_i

$$\hat{\Gamma}_1 = \hat{m}_1(X_i) - \hat{m}_0(X_i) + \frac{W_i - \hat{e}(X_i)}{\hat{e}(X_i)(1 - \hat{e}(X_i))} (Y_i - \hat{m}(X_i, W_i))$$
$$e(x) = P(W_i = 1 \mid X_i = x), \quad m(x, w) = E[Y_i(w) \mid X_i = x]$$

然后, 使用优化方法找到受限于策略类别 Π 的估计值 $\hat{\pi}$

之前我们一直秉持着先考虑利益的原则，无论是在 DID 还是 PL 中，但在实际应用到科创政策中时，过于关注利益可能会损害少数群体的权益并导致不公平，如贫困地区得到的考虑较少等。

因此，我们可以使用 Viviano 和 Bradic (2023) 提出的 FTP 方法，在“首先不造成伤害”的基础上，在公平性和效率之间取得平衡。该方法的思想是在策略类 Π （帕累托效率）内同时最大化每个群体的福利，然后选择其中最公平的有效策略。

三个定义公平的方式:

- Prediction disparity 预测差异: 捕捉组间治疗概率之间的差异
 $E[\pi(X, S) \mid S = 0] - E[\pi(X, S) \mid S = 1]$
- Welfare disparity 福利差异: 衡量两组之间的福利差异
 $E[Y(\pi(X)) \mid S = 1] - E[Y(\pi(X)) \mid S = 0]$
- Relative welfare disparity 相对福利差异:
 $E[(Y(1) - Y(0))\pi(X) \mid S = 1] - E[(Y(1) - Y(0))\pi(X) \mid S = 0]$

Proposition (决策问题): 在假设 (政策制定者的偏好) 下, 如果存在某个 $\alpha \in (0, 1)$ $\pi^* \in \mathcal{C}(\Pi)$, 当且仅当满足以下条件:

$$\pi \in \operatorname{argmin}_{\pi \in \Pi} \text{Unfairness}(\pi) \text{ s.t. } \alpha W_i(\pi) + (1 - \alpha) W_0(\pi^*) \geq \bar{W}_\alpha$$

帕累托前沿:

$$\Pi_0 = \pi(x, s) = \beta_s, \beta_0 = \frac{\phi - p_1 \beta_1}{p_0}, \beta_1 \in [0, 1] \subset \Pi$$

估计的政策: (优化: 混合整数二次规划)

$$\hat{\pi}_\lambda \in \operatorname{argmin}_{\pi \in \hat{\Pi}_0(\lambda)} \mathcal{V}_n(\pi)$$

其中 $\mathcal{V}_n(\pi)$ 定义为 $\text{Unfairness}(\pi)$ 的无偏估计。

该课题致力于运用政策学习方法，通过系统的分析和评估，深入理解政策的实施效果及其对社会的影响。同时，希望填补中文文献在政策优化领域的研究空缺，为中国的政府改革和政策制定提供有益的参考和指导。通过采用科学的数据分析和优化方法，有助于发现政策存在的问题和瓶颈，并提出相应的改进策略。这样可以使政策更加精确地满足社会需求，提高资源配置的效率，促进公平和可持续发展。

在当前全面建设社会主义现代化国家的背景下，科学评估政策效果并进一步优化政策对于推进国家治理体系和治理能力现代化具有重要意义。我们将为政策制定者和实施者提供有益的建议和借鉴，以推动国家治理能力的提升，实现国家治理体系现代化的目标。